

EDA (Exploratory Data Analysis)

1. 데이터셋 정보

- 데이터명 : Synthetic Gym Membership Churn Dataset (1M Rows)
- 출처 : Kaggle (Emin Karltepe)
- 데이터 개수 : 1,000,000건 (Rows)
- 컬럼 수 : 19개 (Columns)
- 목표 변수(Target) : Churn (0: 유지, 1: 이탈)

2. 컬럼 정보

컬럼명	설명	Type
Member_ID	고유 회원 식별자	int64
Age	고객 연령	int64
Gender	성별 범주	str
Membership_Type	헬스장 회원권 플랜	str
Membership_Start_Date	멤버십 시작일	str
Monthly_Fee	월간 구독료	float64
Monthly_Visits	월간 방문 횟수	int64
Avg_Workout_Duration_Min	평균 운동 시간(분)	int64
Peak_Hour_Preference	선호하는 헬스장 이용 시간	str
Cardio_Preference	선호하는 유산소 운동 기구	str
Treadmill_Avg_Speed_Kmh	러닝머신 평균 속도(km/h)	float64
Treadmill_Avg_Incline_Pct	러닝머신 평균 경사도(%)	float64
Group_Class_Attendance	그룹 수업 참여 횟수	int64
PT_Session_Count	개인 트레이너(PT) 세션 횟수	int64
Supplement_Usage	보충제 사용 여부/범주	str
Avg_Equipment_Wait_Time_Min	평균 장비 대기 시간(분)	float64
Late_Payment_Count	연체 건수	int64
Profile_Type	시뮬레이션된 고객 프로필	str
Churn	이탈(0/1)	int64

전처리 전 데이터 타입 확인

Type	개수
int64	8
float	4
str	7

3. 결측치 확인

결측치 개수

컬럼명	결측치	처리 방법	처리 이유
Cardio_Preference	226685	None -> No Preference	유산소 운동을 선호 하지 않는 경우를 고려
Treadmill_Avg_Speed_Kmh	662402	Median	연속형 수치 데이터이며 결측치가 많기 때문에 제거 불가능
Treadmill_Avg_Incline_Pct	662402	Median	연속형 수치 데이터이며 결측치가 많기 때문에 제거 불가능
Supplement_Usage	419573	None -> No Protein Supplements	프로틴을 사용하지 않는 경우를 고려


4. 중복 데이터 확인

- 중복 데이터 개수 : 0
- 처리 방법 : 없음
- 처리 이유 : 없음

5. 이상치 확인

확인 방법

- Box Plot



- IQR

Column	Outlier Count	Outlier Ratio (%)
Age	58968	5.9
Monthly_Fee	0	0.0
Monthly_Visits	25120	2.51
Avg_Workout_Duration_Min	0	0.0
Treadmill_Avg_Speed_Kmh	0	0.0
Treadmill_Avg_Incline_Pct	0	0.0
Group_Class_Attendance	0	0.0
PT_Session_Count	241998	24.2
Avg_Equipment_Wait_Time_Min	0	0.0
Late_Payment_Count	0	0.0
Churn	0	0.0


처리 결과

처리 결과 - Age, Monthly_Visits, PT_Session_Count에서 일부 이상치가 확인되었으나 실제 회원의 다양한 이용 패턴을 반영하는 값으로 판단하여 제거하지 않았다.

6. 데이터 분포

수치형 변수

수치형 변수 분포



수치형 컬럼 8개(Churn 제외)에 대해 Churn=0(잔존) / Churn=1(이탈) 그룹 간 평균·중앙값·표준편차·최소/최대를 비교하고, Churn과의 피어슨 상관계수를 계산함.

변수별 상세 결과

Age

Churn	평균	중앙값	표준편차	최소	최대
0	31.06	28.0	10.29	16	75
1	30.33	28.0	10.27	16	75

- 평균 차이(Churn=1 - Churn=0): -0.73 (-2.35%)
- 상관계수: -0.0344

Monthly_Fee

Churn	평균	중앙값	표준편차	최소	최대
0	48.99	48.06	22.08	21.31	118.59
1	48.99	48.07	22.06	20.89	118.17

- 평균 차이(Churn=1 - Churn=0): 0.0 (0.0%)
- 상관계수: -0.0001

Monthly_Visits

Churn	평균	중앙값	표준편차	최소	최대
0	10.42	10.0	6.78	0	28
1	8.70	8.0	6.60	0	28

- 평균 차이(Churn=1 - Churn=0): -1.72 (-16.51%)
- 상관계수: -0.1237

Avg_Workout_Duration_Min

Churn	평균	중앙값	표준편차	최소	최대
0	73.32	74.0	28.23	0	120
1	71.17	73.0	30.49	0	120

- 평균 차이(Churn=1 - Churn=0): -2.15 (-2.93%)
- 상관계수: -0.0359

Group_Class_Attendance

Churn	평균	중앙값	표준편차	최소	최대
0	6.04	6.0	3.81	0	12
1	5.42	5.0	3.84	0	12

- 평균 차이(Churn=1 - Churn=0): -0.62 (-10.26%)
- 상관계수: -0.0784

PT_Session_Count

Churn	평균	중앙값	표준편차	최소	최대
0	0.94	0.0	1.93	0	8
1	0.60	0.0	1.45	0	8

- 평균 차이(Churn=1 - Churn=0): -0.34 (-36.17%)
- 상관계수: -0.0942

Avg_Equipment_Wait_Time_Min

Churn	평균	중앙값	표준편차	최소	최대
0	11.78	11.6	7.21	0.0	25.0
1	12.58	12.9	7.77	0.0	25.0

- 평균 차이(Churn=1 - Churn=0): +0.8 (+6.79%)
- 상관계수: +0.0526

Late_Payment_Count

Churn	평균	중앙값	표준편차	최소	최대
0	2.64	2.0	1.96	0	6
1	3.57	4.0	1.93	0	6

- 평균 차이(Churn=1 - Churn=0): +0.93 (+35.23%)

- 상관계수: +0.2245

상관계수 기준 정렬 (절댓값 기준 내림차순)

순위	변수	상관계수	방향	해석
1	Late_Payment_Count	+0.2245	양(+)	연체 많을수록 이탈 ↑
2	Monthly_Visits	-0.1237	음(-)	방문 빈도 낮을수록 이탈 ↑
3	PT_Session_Count	-0.0942	음(-)	PT 세션 적을수록 이탈 ↑
4	Group_Class_Attendance	-0.0784	음(-)	그룹 클래스 참석 적을수록 이탈 ↑
5	Avg_Equipment_Wait_Time_Min	+0.0526	양(+)	대기시간 길수록 이탈 ↑ (약함)
6	Avg_Workout_Duration_Min	-0.0359	음(-)	운동시간 짧을수록 이탈 ↑ (약함)
7	Age	-0.0344	음(-)	나이 적을수록 이탈 ↑ (거의 무관)
8	Monthly_Fee	-0.0001	무관	요금과 이탈은 사실상 무관계


인사이트

1. Late_Payment_Count(연체 횟수)가 수치형 변수 중 가장 강한 상관관계(+0.2245)를 보임. Churn=1 그룹의 연체 횟수 평균이 Churn=0 대비 35.23% 높음(2.64건 → 3.57건). 결제 실패/연체가 이탈의 선행 신호일 가능성이 높음.
2. 참여도 지표(Monthly_Visits, PT_Session_Count, Group_Class_Attendance)가 일관되게 음의 상관관계를 보이며, 이는 앞서 범주형 분석(Cardio_Preference의 "No Preference", Supplement_Usage의 "No Protein" 그룹이 이탈률 최고)과 동일한 방향의 패턴. "관여도가 낮을수록 이탈 확률이 높다"는 결론이 수치형·범주형 양쪽에서 일관되게 재확인됨. - Monthly_Visits: 상관계수 -0.1237로 수치형 변수 중 2위, 평균 차이 -16.51% - PT_Session_Count: 평균 차이가 가장 큰 비율(-36.17%)을 보이지만 절대값(0.94 → 0.60)이 작아 상관계수 자체는 -0.0942로 중간 수준
3. Monthly_Fee는 Churn과 사실상 무관. 특히 Monthly_Fee는 상관계수 -0.0001로 완전한 무관계 → 가격(요금) 자체는 이탈의 원인이 아님. 이는 앞선 범주형 분석에서 Membership_Type(요금제 등급)이 이탈률에 영향을 주지 않았던 것과 일치하는 결과 —
4. Avg_Equipment_Wait_Time_Min은 유일하게 "불편함 지표"로서 양의 상관관계(+0.0526)를 보임. 대기시간이 길수록 이탈 확률이 소폭 증가하는 경향이나, 상관계수 자체는 약한 수준. 전체적으로 모든 수치형 변수의 상관계수가 절댓값 0.22 이하로 약한 편 → 단일 수치형 변수만으로는 이탈을 설명하기 어렵고, Late_Payment_Count와 참여도 지표들을 결합한 다변량 모델(로지스틱 회귀, 트리 기반 모델 등)이 필요함을 시사.

범주형 분석과의 통합 관전 포인트

- 범주형에서 가장 강력했던 변수: Profile_Type (Drop-out 49.66% vs Hardcore 30.33%, 격차 19.33%p)
- 수치형에서 가장 강력했던 변수: Late_Payment_Count (상관계수 +0.2245)
- 두 변수 모두 "행동/이력 기반" 변수라는 공통점이 있으며, 인구통계/요금제 계열 변수(Gender, Membership_Type, Age, Monthly_Fee)는 범주형·수치형 가리지 않고 이탈에 거의 영향이 없다는 점이 전체 데이터셋의 핵심 패턴으로 재확인됨.
- 다음 단계로는 Profile_Type과 Late_Payment_Count 두 강력 변수 간의 상호작용(예: Profile_Type별 Late_Payment_Count 분포 비교) 확인.

범주형 변수



범주형 컬럼 (7개)

컬럼명	고유값 개수
Gender	2
Membership_Type	4
Membership_Start_Date	1,005
Peak_Hour_Preference	4
Cardio_Preference	5
Supplement_Usage	5
Profile_Type	4

범주형 컬럼별 분포

Gender

값	개수
Female	500,002
Male	499,998

- 사실상 정확히 50:50 → 인위적으로 생성된 균형 분포일 가능성 존재

Membership_Type

값	개수
Standard	449,978
Gold	299,987
Premium	200,370
VIP	49,665

- 등급이 올라갈수록 인원이 정확히 감소하는 피라미드형 구조 (45% → 30% → 20% → 5%)

Membership_Start_Date

- 고유값 1,005개 (날짜)
- 최다: 2024-02-03 (1,093건)
- 최소권: 2025-01-24 (904건)
- 날짜별 편차가 904~1,093건으로 매우 고름 → 계절성(신년 다짐, 여름 시즌 등) 없이 균등 분포로 합성 데이터일 확률이 있으며 변별력이 떨어짐

Peak_Hour_Preference

값	개수
Midday (10-14)	250,332
Late Night (21-24)	250,218
Evening (17-21)	249,851
Morning (6-10)	249,599

- 4개 구간이 거의 정확히 25%씩 분포

Cardio_Preference

값	개수
Treadmill	337,598
No Preference	226,685
Cycling	193,756
Elliptical	145,220
Rowing	96,741

- Treadmill이 34%로 압도적 1위, Rowing이 10%로 최저 → 실제 헬스장 트렌드와 부합하는 불균형 분포

Supplement_Usage

값	개수
No Protein Supplements	419,573
Whey Protein	193,827
Pre-Workout	145,301
Creatine	144,605
Full Stack	96,694

Profile_Type

값	개수
Casual	503,759
Regular	222,581
Drop-out	220,021
Hardcore	53,639

- Casual 50%, Regular·Drop-out 각 22%, Hardcore 5%

Churn 교차분석 (범주형 변수별 이탈률)

Gender

Gender	전체 인원	이탈률
Female	500,002	38.69%
Male	499,998	38.45%

Membership_Type

Membership_Type	전체 인원	이탈률
Standard	449,978	38.54%
Gold	299,987	38.65%
Premium	200,370	38.53%
VIP	49,665	38.51%

Peak_Hour_Preference

Peak_Hour_Preference	전체 인원	이탈률
Midday (10-14)	250,332	38.67%
Late Night (21-24)	250,218	38.55%
Evening (17-21)	249,851	38.58%
Morning (6-10)	249,599	38.49%

Cardio_Preference

Cardio_Preference	전체 인원	이탈률
Treadmill	337,598	37.93%
No Preference	226,685	40.79%
Cycling	193,756	38.06%
Elliptical	145,220	37.89%
Rowing	96,741	37.66%

Supplement_Usage

Supplement_Usage	전체 인원	이탈률
No Protein Supplements	419,573	39.57%
Whey Protein	193,827	37.96%
Pre-Workout	145,301	37.81%
Creatine	144,605	37.69%
Full Stack	96,694	37.94%

Profile_Type

Profile_Type	전체 인원	이탈률
Casual	503,759	37.11%
Regular	222,581	32.90%
Drop-out	220,021	49.66%
Hardcore	53,639	30.33%

변수별 Churn 영향력 정리

영향 거의 없음 (기준선 38.5% $\pm$ 0.3%p 이내)

- Gender: 38.45% ~ 38.69% (차이 0.24%p)
- Membership_Type: 38.51% ~ 38.65% (차이 0.14%p)
- Peak_Hour_Preference: 38.49% ~ 38.67% (차이 0.18%p)

공통점: 세 변수 모두 분포 자체가 균형/피라미드형으로 규칙적으로 나뉜 변수. 분포가 인위적으로 균등하게 생성된 변수일수록 Churn과의 관계도 평평하게 나타남.

약한 영향 (1~3%p 차이)

- Cardio_Preference: 최고 No Preference(40.79%) ↔ 최저 Rowing(37.66%), 차이 3.13%p
- Supplement_Usage: 최고 No Protein(39.57%) ↔ 최저 Creatine(37.69%), 차이 1.88%p

공통 패턴: "운동 종류 무관심" / "보충제 미섭취" 그룹이 이탈률 최고점 → 운동에 대한 관여도가 낮을수록 이탈 경향 증가

강한 영향 (Profile_Type, 최대 19.33%p 차이)

- Drop-out: 49.66% (기준선 대비 +11.16%p, 전체 중 최고)
- Casual: 37.11% (기준선 대비 -1.39%p)
- Regular: 32.90% (기준선 대비 -5.60%p)
- Hardcore: 30.33% (기준선 대비 -8.17%p, 전체 중 최저)
- Drop-out ↔ Hardcore 격차: 19.33%p

교차 인사이트

1. 분포가 정확히 균등한 변수(Gender 50:50, Peak_Hour 25% $\times$ 4)일수록 이탈률도 균등 → 무작위 배정 변수라는 신호로 해석 가능.

2. 분포의 불균형 여부와 이탈률 영향력은 별개. Membership_Type은 분포가 45→30→20→5로 불균형하지만 이탈률엔 영향 없음. 반면 Cardio_Preference, Supplement_Usage, Profile_Type은 불균형하면서 실제 이탈률 차이도 만들.
3. Membership_Start_Date의 날짜별 분포가 지나치게 고름(계절성 없음) → 실제 헬스장 데이터라면 나타날 법한 신년/여름 성수기 패턴이 부재. Gender, Peak_Hour와 함께 합성 데이터(synthetic data) 가능성을 시사하는 근거.
4. "관여도(engagement)"가 이탈의 핵심 축으로 보임. Cardio_Preference의 "No Preference", Supplement_Usage의 "No Protein"처럼 무관심/미참여 그룹이 이탈률 최고점을 기록하는 동일한 패턴이 반복됨. Profile_Type의 Hardcore(최저 이탈)와 Drop-out(최고 이탈) 구도도 같은 맥락.
5. **Profile_Type의 "Drop-out" 범주는 이탈률 49.66%로 다른 범주(Casual 37.11%, Regular 32.90%, Hardcore 30.33%) 대비 압도적으로 높게 나타나, 변수명 자체가 결과를 암시하는 타겟 변수 가능성을 검토함. 다만 Drop-out 그룹의 실제 이탈률이 49.66%로 100%가 아니라 절반 수준에 그치는 점으로 보아 Churn과 완전히 1:1로 매핑되는 완전 변수는 아닌 것으로 판단됨. 이에 따라 Profile_Type은 삭제하지 않고 분석 및 모델링에 그대로 사용하기로 결정함.

미해결 / 다음 단계

아래는 아직 계산하지 않은 항목이며, 가설 단계임을 명시.

- 수치형 컬럼(Age, Monthly_Fee, Monthly_Visits, Avg_Workout_Duration_Min, Group_Class_Attendance, PT_Session_Count, Avg_Equipment_Wait_Time_Min, Late_Payment_Count)과 Churn의 관계 미검증
- 가설: Monthly_Visits, Avg_Workout_Duration_Min, Group_Class_Attendance, PT_Session_Count 등 "참여도 지표"는 이탈과 음의 상관관계를 가질 가능성 (Cardio_Preference/Supplement_Usage 패턴과 유사)
- 가설: Late_Payment_Count는 이탈과 양의 상관관계를 가질 가능성 (연체 많을수록 이탈 많음)
- Membership_Start_Date 기반 파생변수(가입 연차, 가입 요일 등)와 Churn의 관계 미검증

7. 데이터 전처리

7.1 결측치 처리

컬럼명	처리 방법	처리 이유
Cardio_Preference	결측값을 "No Preference"로 대체	유산소 운동을 선호하지 않는 회원으로 간주
Supplement_Usage	결측값을 "No Protein Supplements"로 대체	보충제를 사용하지 않는 회원으로 간주

7.2 이상치 처리

컬럼명	처리 방법	처리 이유
없음	없음	Age, Monthly_Visits, PT_Session_Count에서 일부 이상치가 확인되었으나 실제 회원의 다양한 이용 패턴을 반영하는 값으로 판단하여 제거하지 않았다.

7.3 컬럼 삭제

컬럼명	삭제 이유
Member_ID	고유번호(식별자)로 분석적 의미 없어 제거
Treadmill_Avg_Speed_Kmh	결측치 2/3 이상
Treadmill_Avg_Incline_Pct	결측치 2/3 이상
Gender	분포가 균형(50:50)하며 Churn과의 관계도 평평(차이 0.24%p)하여 제거
Membership_Type	분포가 피라미드형으로 규칙적이며 Churn과의 관계도 평평(차이 0.14%p)하여 제거
Peak_Hour_Preference	분포가 균형(25%×4)하며 Churn과의 관계도 평평(차이 0.18%p)하여 제거
Monthly_Fee	Churn과 상관계수 -0.0001로 사실상 무관계이므로 제거

7.4 feature 엔지니어링

컬럼명	처리 방법	처리 이유
Membership_Start_Date	파생변수 생성(연/월/요일/가입일수) 및 본 데이터 제거	str 형태로 저장되어 있어 날짜 연산 불가 및 파생 변수 생성 후 str 데이터 제거

7.5 인코딩

컬럼명	인코딩 방법	선택 이유
Cardio_Preference	One-Hot Encoding	순서 없는 명목형, 고유값 5개로 카디널리티 낮음
Supplement_Usage	One-Hot Encoding	순서 없는 명목형, 고유값 5개로 카디널리티 낮음
Profile_Type	One-Hot Encoding	순서 없는 명목형, 고유값 4개로 카디널리티 낮음

7.6 스케일링

컬럼명	스케일링 방법	선택 이유
Age	StandardScaler	정규분포에 가까운 분포, 이상치 적음
Monthly_Visits	StandardScaler	분포가 고르고 이상치 적음
Avg_Workout_Duration_Min	StandardScaler	0~120 범위의 연속형, 분포 고름
Treadmill_Avg_Speed_Kmh	StandardScaler	중앙값 대체로 값 범위 자체는 안정적
Treadmill_Avg_Incline_Pct	StandardScaler	중앙값 대체로 값 범위 자체는 안정적
Group_Class_Attendance	StandardScaler	0~12 범위, 분포 고름
PT_Session_Count	RobustScaler	0에 몰린 왜도 큰 분포 → 이상치에 강건한 스케일링 필요
Avg_Equipment_Wait_Time_Min	StandardScaler	연속형이며 분포 고름
Late_Payment_Count	RobustScaler	Churn과 상관 가장 높은 변수, 분포가 한쪽에 치우침 → 이상치에 강건한 스케일링 필요

One-Hot Encoding으로 생성된 Cardio_Preference_*, Supplement_Usage_*, Profile_Type_* 더미 컬럼(0/1)과 타겟 Churn은 스케일링 대상에서 제외.

7.7 Feature Selection


Feature	선택 여부	선택 이유
Member_ID	제외	고유 식별자로 분석적 의미 없음
Age	포함	Churn과 약한 상관(-0.0344)이나 도메인상 의미 있어 유지, 스케일링 후 사용
Gender	제외	분포 균형(50:50), Churn과 관계 평평하여 변별력 없음
Membership_Type	제외	분포 피라미드형으로 규칙적, Churn과 관계 평평하여 변별력 없음
Membership_Start_Date	제외 (파생변수로 대체)	원본 날짜는 카디널리티 과다, Start_Year/Start_Month/Start_Weekday/Membership_Days로 대체
Monthly_Fee	제외	Churn과 상관계수 -0.0001로 사실상 무관계
Monthly_Visits	포함	Churn과 상관계수 -0.1237로 수치형 중 2위, 참여도 지표로서 의미 있음
Avg_Workout_Duration_Min	포함	약한 음의 상관(-0.0359)이나 참여도 지표로서 유지
Peak_Hour_Preference	제외	분포 균형(25%×4), Churn과 관계 평평하여 변별력 없음
Cardio_Preference	포함 (One-Hot 인코딩)	"No Preference" 그룹 이탈률 최고(40.79%), 관여도 지표로 유의미
Treadmill_Avg_Speed_Kmh	포함 (결측치 중앙값 대체 후 스케일링)	결측 비율 높으나 삭제보다 대체로 정보 보존
Treadmill_Avg_Incline_Pct	포함 (결측치 중앙값 대체 후 스케일링)	결측 비율 높으나 삭제보다 대체로 정보 보존
Group_Class_Attendance	포함	Churn과 상관계수 -0.0784, 참여도 지표로서 의미 있음
PT_Session_Count	포함	Churn과 상관계수 -0.0942, 참여도 지표 중 상관 높은 편
Supplement_Usage	포함 (One-Hot 인코딩)	"No Protein" 그룹 이탈률 최고(39.57%), 관여도 지표로 유의미
Avg_Equipment_Wait_Time_Min	포함	Churn과 상관계수 +0.0526, 불편함 지표로서 유의미
Late_Payment_Count	포함	Churn과 상관계수 +0.2245로 수치형 중 가장 강한 상관관계
Profile_Type	포함 (One-Hot 인코딩, 단 타겟 누수 검증 필요)	이탈률 격차 최대 19.33%p로 가장 강력한 변수, 단 leakage 의심되어 검증 후 최종 포함 여부 재확인
Churn	타겟 (Feature 아님)	예측 대상 변수

8. 상관관계 분석

분석 방법

- Correlation Matrix
- Heatmap

상관관계 히트맵



주요 결과


변수명	Churn과의 상관계수
Late_Payment_Count	0.2245
Monthly_Visits	-0.1237
Profile_Type_Drop-out	0.1210
PT_Session_Count	-0.0942
Membership_Days	-0.0899
Start_Year	0.0839
Group_Class_Attendance	-0.0784
Profile_Type_Regular	-0.0624
Avg_Equipment_Wait_Time_Min	0.0526
Profile_Type_Hardcore	-0.0403
Avg_Workout_Duration_Min	-0.0359
Age	-0.0344
Cardio_Preference_No Preference	0.0247
Supplement_Usage_No Protein Supplements	0.0174
Cardio_Preference_Treadmill	-0.0094
Supplement_Usage_Pre-Workout	-0.0064
Supplement_Usage_Whey Protein	-0.0062
Cardio_Preference_Rowing	-0.0062
Cardio_Preference_Elliptical	-0.0058
Supplement_Usage_Full Stack	-0.0043
Start_Weekday	0.0008
Start_Month	-0.0005

분석

1. Late_Payment_Count(연체 건수)가 전체 변수 중 Churn과 가장 강한 상관관계(0.2245)를 보임. 연체가 많을수록 이탈 확률이 높아지는 경향이 뚜렷하며, 이는 이전 수치형 분석 결과와 일치.
2. Monthly_Visits(-0.1237), PT_Session_Count(-0.0942), Group_Class_Attendance(-0.0784)가 모두 음의 상관관계로 일관됨. 방문 빈도, PT 세션, 그룹 클래스 참여가 적을수록 이탈 확률이 높아지는 패턴으로, "관여도가 낮을수록 이탈한다"는 기존 가설을 재확인.
3. Profile_Type_Drop-out(0.1210)이 One-Hot 변수 중 가장 강한 상관관계를 보이며, 전체 변수 중에서도 3위. 반대로 Profile_Type_Regular(-0.0624), Profile_Type_Hardcore(-0.0403)는 음의 상관관계를 보여, Drop-out 프로필과 나머지 프로필 간 이탈 방향이 뚜렷하게 갈림. 다만 이전에 언급한 대로 이 변수는 타겟 누수 가능성이 있어 해석에 주의 필요.
4. Membership_Days(-0.0899)와 Start_Year(0.0839)는 서로 반대 방향이지만 사실상 같은 정보(가입 시점)를 담고 있음. 가입한 지 오래된 회원(Membership_Days 큼)일수록 이탈 확률이 낮고, 최근에 가입한 회원(Start_Year 큼)일수록 이탈 확률이 높은 경향 → 신규 회원의 초기 이탈(온보딩 실패) 가능성을 시사.
5. Avg_Equipment_Wait_Time_Min(0.0526)은 유일하게 "불편함" 계열 지표로서 양의 상관관계를 보임. 대기시간이 길수록 이탈 확률이 소폭 증가.
6. Cardio_Preference, Supplement_Usage 계열 One-Hot 변수들은 대부분 상관계수 절댓값 0.03 미만으로 매우 약함. 앞선 groupby 분석에서는 "No Preference", "No Protein" 그룹의 이탈률이 다소 높게 나왔지만, 전체 상관관계 매트릭스 기준으로 는 예측력이 크지 않은 보조 변수 수준.
7. Start_Weekday(0.0008), Start_Month(-0.0005)는 사실상 Churn과 무관. 가입 요일이나 월은 이탈에 영향을 주지 않는 것으로 확인됨 → 추후 모델링 시 우선순위에서 제외하거나 sin/cos 변환 없이 단순

9. 타겟 변수 분석

이탈 여부 분포



클래스 분포

Churn	인원 수	비율
0 (잔존)	614,298	61.43%
1 (이탈)	385,702	38.57%

클래스 불균형 여부

- 클래스 불균형 비율(다수:소수) = 1.59 : 1
- 이탈률이 38.57%로 낮지 않은 편이며, 다수/소수 클래스 비율이 약 1.6배 수준으로 극단적인 불균형은 아님
- 일반적으로 5:1 이상부터 심각한 불균형으로 간주하는 기준에 비춰보면, 지금 데이터는 경미한 불균형 수준
- SMOTE 같은 오버샘플링 없이도 학습이 가능한 수준이나, 모델 성능 평가 시 Accuracy보다는 F1-score, Recall, ROC-AUC 등 불균형에 덜 민감한 지표를 우선 사용 권장
- 필요시 `class_weight="balanced"` 옵션(Logistic Regression, XGBoost의 `scale_pos_weight`) 정도로 간단히 보정하는 것으로 충분할 것으로 판단됨

Feature Importance

주요 영향 변수 Top 15

순위	Feature	Importance
1	Late_Payment_Count	0.5128
2	Monthly_Visits	0.1108
3	PT_Session_Count	0.0798
4	Start_Year	0.0781
5	Membership_Days	0.0364
6	Group_Class_Attendance	0.0362
7	Avg_Equipment_Wait_Time_Min	0.0347
8	Age	0.0201
9	Supplement_Usage_No Protein Supplements	0.0074
10	Cardio_Preference_Rowing	0.0074
11	Avg_Workout_Duration_Min	0.0073
12	Supplement_Usage_Pre-Workout	0.0071
13	Supplement_Usage_Full Stack	0.0070
14	Cardio_Preference_No Preference	0.0069
15	Start_Month	0.0069

주요 인사이트

- Late_Payment_Count가 0.5128로 가장 높은 중요도를 기록하여, 회원 이탈 예측에서 결제 연체 이력이 가장 중요한 변수로 확인되었다.
- Monthly_Visits와 PT_Session_Count는 회원의 이용 빈도와 참여도를 나타내며, 활동성이 낮은 회원일수록 이탈 가능성이 증가하는 패턴을 보였다.
- Start_Year, Membership_Days는 가입 시점과 이용 기간에 따른 회원 유지 패턴을 반영하는 변수로 확인되었다.
- Group_Class_Attendance, Avg_Equipment_Wait_Time_Min은 헬스장 이용 경험 및 만족도와 관련된 변수로 이탈 예측에 영향을 주었다.
- 운동 선호도 및 보충제 사용 여부와 같은 범주형 변수는 개별 중요도는 낮지만 회원 특성을 구분하는 보조 변수로 활용되었다.

결론

Feature Importance 분석 결과, 회원 이탈은 단순한 운동 선호도보다 결제 행동(Late_Payment_Count), 이용 빈도(Monthly_Visits), 운동 참여도(PT_Session_Count, Group_Class_Attendance), 가입 기간(Membership_Days)과 같은 행동 기반 변수가 주요 영향을 미치는 것으로 확인되었다.

따라서 이탈 방지를 위해 연체 발생 회원 및 방문 빈도가 감소한 회원을 대상으로 선제적인 리텐션 전략을 적용하는 것이 효과적이다.

11. 최종 데이터셋

컬럼명	설명	Type
Age	고객 연령	int64
Monthly_Visits	월간 방문 횟수	int64
Avg_Workout_Duration_Min	평균 운동 시간(분)	int64
Treadmill_Avg_Speed_Kmh	러닝머신 평균 속도(km/h), 결측치 중앙값 대체	float64
Treadmill_Avg_Incline_Pct	러닝머신 평균 경사도(%), 결측치 중앙값 대체	float64
Group_Class_Attendance	그룹 수업 참여 횟수	int64
PT_Session_Count	개인 트레이너(PT) 세션 횟수	int64
Avg_Equipment_Wait_Time_Min	평균 장비 대기 시간(분)	float64
Late_Payment_Count	연체 건수	int64
Start_Year	멤버십 시작 연도 (Membership_Start_Date 파생)	int32
Start_Month	멤버십 시작 월 (Membership_Start_Date 파생)	int32
Start_Weekday	멤버십 시작 요일, 0(월)~6(일) (Membership_Start_Date 파생)	int32
Membership_Days	기준일 대비 가입 경과 일수 (Membership_Start_Date 파생)	int64
Cardio_Preference_*	선호 유산소 운동 기구, One-Hot 인코딩 (drop_first)	uint8 / bool
Supplement_Usage_*	보충제 사용 여부, One-Hot 인코딩 (drop_first)	uint8 / bool
Profile_Type_*	고객 프로필 유형, One-Hot 인코딩 (drop_first)	uint8 / bool
Churn	이탈(0/1), 타겟 변수	int64

Type	개수
int64	2
int32	3
float64	7
bool	11

항목	값
샘플 수	1,000,000
컬럼 수	23

12. 저장 파일

파일명	설명
churn_100.csv	전체 데이터
churn_50.csv	50% 데이터

13. 결론

주요 데이터 특징

- 총 100만 행, 16개 컬럼(수치형 9 + 범주형 7), 결측치는 Treadmill 관련 2개 컬럼을 제외하면 없음
- 전체 이탈률은 38.57%로, 클래스 불균형은 경미한 수준(1.59:1)
- 인구통계·요금제 계열 변수(Gender, Membership_Type, Peak_Hour_Preference, Monthly_Fee, Age)는 Churn과 거의 무관
→ 균등하게 생성된 변수일수록 이탈률도 균등하게 나타나는 패턴 확인

- 행동/이력 기반 변수(Late_Payment_Count, Monthly_Visits, Profile_Type, PT_Session_Count, Group_Class_Attendance)가 Churn과 상대적으로 강한 상관관계를 보임 → “관여도가 낮을수록, 연체가 많을수록 이탈 확률이 높다”는 일관된 패턴이 범주형·수치형 분석 모두에서 재확인됨
- Profile_Type_Drop-out은 상관관계가 가장 강한 변수 중 하나이나, 카테고리명 자체가 결과를 암시하고 있어 타겟 누수 가능성이 의심됨

수행한 전처리 요약

1. 컬럼 삭제: Member_ID, Gender, Membership_Type, Peak_Hour_Preference, Monthly_Fee, Treadmill_Avg_Speed_Kmh/Incline_Pct(대체 후 유지 또는 삭제 검토)
2. 결측치 처리: Cardio_Preference-Supplement_Usage는 결측값을 “선호 없음/미사용” 범주로 대체, Treadmill 관련 2개 컬럼은 중앙값 대체
3. 파생변수 생성: Membership_Start_Date → Start_Year, Start_Month, Start_Weekday(숫자형), Membership_Days로 분리 후 원본 삭제
4. 인코딩: Cardio_Preference, Supplement_Usage, Profile_Type → One-Hot Encoding(drop_first=True)
5. 스케일링: 연속형 변수는 StandardScaler, 왜도 큰 변수(PT_Session_Count, Late_Payment_Count)는 RobustScaler 적용
6. Feature Selection: XGBoost Feature Importance 기준 상위 50% 변수만 최종 선택

전처리 이유

- 분포가 균등하거나 Churn과 상관관계가 거의 없는 변수는 모델 학습에 노이즈로 작용할 수 있어 사전 제거
- 날짜형 데이터는 그대로 두면 모델이 연산할 수 없어 숫자형 파생변수로 변환
- 명목형 범주 변수는 순서 정보가 없어 Label Encoding 대신 One-Hot Encoding을 채택하여 선형/딥러닝 모델에서의 서열 오해를 방지
- 이상치에 민감한 변수는 RobustScaler로, 나머지는 StandardScaler로 구분 적용하여 스케일링 왜곡을 최소화
- 다수 모델(Logistic, XGBoost, Deep Learning) 비교를 전제로, 모든 모델에 공통으로 적용 가능한 전처리 파이프라인 하나로 통일

모델 학습 시 고려사항

- 클래스 불균형이 경미하지만, Accuracy보다는 F1-score, Recall, ROC-AUC 등 불균형에 덜 민감한 지표로 평가 필요
- Logistic Regression, Deep Learning은 스케일링이 필수이나 XGBoost는 불필요 → 동일 파이프라인 사용 시 성능에 해는 없으나 불필요한 연산이 포함될 수 있음
- Profile_Type_Drop-out의 타겟 누수 가능성을 검증 후 모델링에 반영해야 함 (누수 확인 시 제외 또는 가중치 조정 필요)
- Train/Test 분리 후 스케일링은 반드시 Train 기준으로 fit하고 Test에는 transform만 적용해야 데이터 누수 방지 가능

데이터의 한계 및 개선 방향 (선택)

- Membership_Start_Date의 날짜별 분포와 Gender-Peak_Hour_Preference의 정확히 균등한 분포는 실제 데이터라기보다 합성(synthetic) 데이터일 가능성을 시사 → 실제 서비스 적용 시 재검증 필요
- Treadmill_Avg_Speed_Kmh, Treadmill_Avg_Incline_Pct는 결측 비율이 2/3 이상으로 매우 높아, 중앙값 대체가 실제 분포를 왜곡했을 가능성 존재 → 추가 수집 또는 별도 모델링(결측 여부 자체를 변수화)을 고려할 수 있음
- Profile_Type의 생성 로직(가입 시점 vs 이탈 후 부여)이 확인되지 않아 모델 해석의 신뢰도에 제약이 있음
- 현재 상관관계 분석은 선형 관계(피어슨 상관관계수) 기준이므로, 비선형 관계를 가진 변수(Age 등)는 과소평가되었을 가능성이 있음